Case Study: Obesity

20102105 Kim Seungjun 21102052 Lee Jeong-Yun 21102061 Hwang Hyunmin

Contents

Z. Background

3. Case 2

Problems

Dataset

Methods

Results

Limitations

2 Case 1

Dataset

Methods

Results


Limitations

References

Citations

Background

Problems



issues.

Modern lifestyles shaped by industrialization and urbanization have led to reduced physical activity and unhealthy dietary patterns.

This has contributed to a global rise in obesity and related mental health

The COVID-19 pandemic intensified isolation, stress, and depression. These psychological effects have been linked to increased BMI, alcohol use, and unhealthy behaviors.

Obesity is not caused by a single factor, but by interacting variables: socioeconomic status, mental health, sleep, diet, and physical inactivity.

Traditional models are limited in capturing this complexity.

Data mining enables the discovery of hidden patterns and the prediction of high-risk groups.

Case 1

Exploring Factors for Predicting Depression

Experiences Beyond BMI Overweight Using Data Mining

Models in the Post-COVID-19 Era

by Kyung-II Hwang

Dataset

Korea National Health and Nutrition Examination Survey (KNHANES), Phase 7 (2018) & Phase 8 (2021)

Preprocessing

Variable transformation and normalization, handling missing values SMOTE for class imbalance 70:30 split for training/evaluation datasets

Population

Initial Subjects: 15,082

→ Adults aged 19-64 = 11,478

→ Overweight adults = 6,052

Final Sample: 2,216 respondents with valid depression experience responses

Variables Summary

Demographics: Gender, Age, Employment status, Education level, Marital status, BMI

Health Behavior: Sleep duration, Walking activity, Smoking/drinking experience

Psychosocial: Self-rated health, Stress awareness, Social isolation



Variable Significance Testing

- Before building the models, statistical tests were conducted to evaluate the relationship between each variable and depression status.
- Categorical variables were tested using Chi-square (χ^2) and Fisher's Exact Test.
- Continuous variables were tested using the Mann-Whitney U Test.
- The significance level was set at p < 0.05.

 \rightarrow Statistically significant variables (e.g., gender, employment status, education level, BMI) helped identify key patterns, but all variables were included in the machine learning models to capture potential interactions.

Variable Significance Testing

<표 1> COVID-19 발생 전·후 신체적 요인 변화

			cov	ID-19			
	구 분	발생 전		발생	발생 후		
			%	N	%	- X ² /Z	Р
	신장(cm)	165.13	8.88	165.51	8.97	-1.778	0.075
	체중(kg)	65.39	13.16	66.32	13.89	-2.703	0.007
허리둘레(cm)		81.21	10.43	82.87	11.11	-6.792	0.000
체질량지수(BMI)		23.86	3.68	24.07	3.86	-2.540	0.011
	18.5 미만(저체중)	232	4.8	241	5.9		
	18.5~22.9(정상)	2,099	43.4	1,657	40.3	-	
체질량지수 범주 (BMI)	23.0~24.9(과체중)	1,048	21.7	887	21.5	17.700	0.001
(2)	25.0~29.9(비만)	1,141	23.6	997	24.2	-	
	30.0 이상(고도비만)	316	6.5	332	8.1	-	
우울감	예	-	-	242	10.9		
우울감 경험 [†]	아니요	-	-	1,974	89.1		

N: frequency, %: percentage, P-value <0.05, X2: Chi-square test,

Z: mann-whitney test, † 2021년만 조사된 문항

<표 2> BMI 과체중 이상 우울감 경험 유무와 일반적 특성

	7.8			상 우울감		- 22:=	
	구분	N O	4I %	아L N	, l표	X²/Z	р
ин	남자	105	8.5	1,124	91.5	40.007	(1000)
성별 -	여자	137	13.9	850	86.1	- 16.027	<0.001
	나이	46.36	12.70	45.88	12.33	-0.703	0.482
경제활동 -	예(취업자)	158	10.1	1,399	89.9		
상태	아니요(실업자, 비경제활동인구)	119	18.1	540	81.9	20.354	<0.001
	≤ Middle school	69	21.0	259	79.0		
교육수준	> Middle or graduate school	208	11.0	1,680	89.0	9.893	0.002
결혼 여부 -	기혼	174	10.3	1,513	89.7	- 2.671	0.102
25 41	미혼	68	12.9	461	87.1	2.071	0.102
	유배우자, 동거	133	8.9	1,357	91.1		
- 경하사데	유배우자, 별거	1	8.3	11	91.7	04.400	10.004
결혼상태 -	사별	9	22.0	32	78.0	24.480	<0.001
-	이혼	31	21.5	113	78.5	-	
평생 음주	없음	16	14.2	97	85.8	4 004	0.057
경험	있음	226	10.7	1,877	89.3	1.284	0.257
	5갑(100개비) 미만	6	9.5	57	90.5		
평생 일반담배 [*] 흡연 여부	5갑(100개비) 이상	107	10.6	907	89.4	0.469	0.791
	피운 적 없음	129	11.3	1,010	88.7	(0)	
{	닌장(cm)	164.95	9.67	167.03	9.31	-3.192	0.001

		BMI 과체중 이상 우울감 경험					
	구분		예	아니	요	X ² /Z	р
		N	%	N	%		
	체중(kg)	72.14	13.02	74.37	12.12	-3.328	<0.001
허리	리둘레(cm)	89.25	8.02	89.68	8.65	-0.622	0.534
체질	량지수(BMI)	26.38	3.04	26.57	3.05	-0.747	0.455
	23.0~24.9(과체중)	90	10.8	740	89.2		
체질량지수 범주	25.0~29.9(비만)	128	11.5	982	88.5	1.835	0.399
	30.0 이상(고도비만)	24	8.7	252	91.3		
	전혀 하지 않음	43	12.0	314	88.0		
	1일	10	7.1	130	92.9		
-	2일	20	7.6	243	92.4		
1주일간	3일	38	13.4	245	86.6	0.000	0.446
걷기일 수	4일	19	10.6	160	89.4	- 6.833 -	
	5일	30	11.2	237	88.8		
	6일	16	11.9	119	88.1		
	7일(매일)	66	11.1	526	88.9		
	전혀 하지 않음	172	10.7	1,442	89.3		
	1일	8	9.4	77	90.6		
1주일간	2일	9	7.8	107	92.2	4 120	0.530
근력운동일 수	3일	13	10.0	117	90.0	4.138	0.550
	4일	9	14.3	54	85.7		
	5일 이상	29	13.9	179	86.1		
유산소	실천하지 않음	124	10.5	1,055	89.5	0.288	0.591
신체활동 실천-	실천	117	11.3	920	88.7	0.200	A THE
N : frequenc	v. %: percentage.	P-value	< 0.05	X ² : Chi	-square	test.	-

N: frequency, %: percentage, P-value <0.05, X²: Chi-square test,

Z: mann-whitney test

Variable Significance Testing

<표 3> BMI 과체중 우울감 경험과 주관적 인식과 신체 요인

10kg 이상

		BMI :	과체중 이	상 우울김	경험				BMI 3	과체중 이	상 우울감	경험	
	구분		예	아니	요	X ² p	구분		예		아니요		
		N	%	N	%				N	%	N	%	
	매우 나쁨	20	8.3	28	1.4			3kg 이상 ~ 6kg 미만	74	61.7	517	67.9	
	나쁨	71	29.3	274	13.9	-	1년간 체중 증가량	6kg 이상 ~ 10kg 미만	21	17.5	170	22.3	
주관적 건강인지	보통	113	46.7	983	49.8	105.519 < 0.001	1년간 체중 조절 여부	10kg 이상	25	20.8	74	9.7	
,	좋음	31	12.8	586	29.7	_			체중 감소 노력	149	61.6	1,095	55.5
	 매우 좋음	7	2.9	103	5.2	-		체중 유지 노력	40	16.5	376	19.0	
	 매우 마른 편	1	0.4	0	0.0			체중증가 노력	1	0.4	19	1.0	
	약간 마른 편 1		0.4	14	0.7	_		체중 조절 노력해본 적 없음	52	21.5	484	24.5	
주관적 체형인식	보통	45	18.6	469	23.8	11.004 0.023	평소 스트레스	대단히 많이 느낀다	8	3.3	261	13.2	
	약간 비만	128	52.9	1,065	54.0			많이 느끼는 편이다	70	28.9	1,237	62.7	
•	매우 비만	67	27.7	426	21.6	-	인지 정도	조금 느끼는 편이다	111	45.9	407	20.6	
	변화 없음	79	32.6	977	49.5			거의 느끼지 않는다	53	21.9	69	3.5	
1년간 체중 변화 여부	체중 감소	43	17.8	236	12.0	25.232 <0.001	N: frequency, %: percentage, P-value		e <0.05	$X^{2}: C$	Chi-squar	e test,	
	체중 증가	120	49.6	761	38.6	_	Z: mann-white	ney test					
	3kg 이상 ~ 6kg 미만	24	55.8	162	68.6								
1년간 체중 감소량	6kg 이상 ~ 10kg 미만	7	16.3	50	21.2	10.196 0.006							
	401 0144	4.2	27.0	2.4	40/4	1							

<표 4> BMI 과체중 이상 우울감 경험과 주요 질환

			BMI 3	마체중 이	상 우울감	경험		
	구분		0	4	아니	요	X ²	р
			N	%	N	%		
	고혈압 _	없음	181	74.8	1,571	79.6	- 2.989	0.084
)	- 26	있음	61	25.2	403	20.4	2.303	0.004
-	이사되지형조	없음	174	71.9	1,562	79.1	0.007	0.040
	이상지질혈증	있음	68	28.1	412	20.9	6.637	0.010
	뇌졸중 —	없음	248	90.2	1,900	97.9	2.497	0.173
	되글장 -	있음	27	9.8	41	2.1	2.491	0.173
	심근경색증 또는 협심증 _	없음	246	89.5	1,892	97.5	3.382	0.087
)		있음	29	10.5	49	2.5	0.002	0.001
	당뇨병 _	없음	216	89.3	1,810	91.7		0.201
-	ο±ο -	있음	26	10.7	164	8.3	- 1.632	0.201
	빈혈	없음	223	86.4	1,833	93.6	6.492	0.011
	건설 -	있음	35	13.6	125	6.4	0.492	0.011
								A STATE OF THE PARTY OF THE PAR

N: frequency, %: percentage, P-value <0.05, X2: Chi-square test,

Z: mann-whitney test

• Logistic Regression:


 A statistical model that predicts the probability of depression based on a weighted combination of input variables.

• Neural Network:

- A structure of interconnected layers (input → hidden → output)
 that processes information by passing signals through nodes.
- It learns patterns in the data by adjusting the weights in the network during training.

CHAID Decision Tree:

 Similar to general decision trees, but CHAID splits based on chisquare test results and can produce more than two branches at once, making it suitable for analyzing categorical data and visualizing multiple outcome paths.



<표 6> 로지스틱 회귀분석(Logistic Regression) 방정식 변수 결과표

	7.11		이이치로	E (D)	EXP(B)에 대힌	95% 신뢰구간
	구분	В	유의확률	Exp(B)	하한	상한
	성별(여자)	0.333	0.480	1.396	0.554	3.519
	경제활동 상태(아니요)	0.337	0.267	1.401	0.772	2.541
	교육 수준(중학교 졸업 이상)	0.243	0.523	1.275	0.605	2.686
	결혼상태		0.054			
_	결혼상태(유배우자, 별거)	-0.198	0.887	0.821	0.053	12.709
	결혼상태(사별)	1.407	0.048	4.084	1.014	16.456
ш.	결혼상태(이혼)	0.866	0.038	2.378	1.051	5.380
변수 —	신장	0.016	0.623	1.016	0.954	1.082
	체중	-0.012	0.553	0.988	0.950	1.028
	주관적 건강인지		0.052			
	주관적 건강인지(나쁨)	-0.469	0.466	0.626	0.177	2.207
	주관적 건강인지(보통)	-0.872	0.174	0.418	0.119	1.470
	주관적 건강인지(좋음)	-1.861	0.013	0.156	0.036	0.673
_	주관적 건강인지(매우 좋음)	-0.888	0.386	0.411	0.055	3.062

п		이하다	F(D)	EXP(B)에 대한	95% 신뢰구간
구분	В	유의확률	Exp(B)	하한	상한
주관적 체형 인식		0.719			
주관적 체형 인식(보통)	-0.289	0.543	0.749	0.295	1.903
주관적 체형 인식(약간비만)	-0.467	0.418	0.627	0.203	1.939
1년간 체중 증가량		0.050			
1년간 체중 증가량(감소)	-0.672	0.091	0.511	0.234	1.114
1년간 체중 증가량(증가)	0.588	0.188	1.800	0.750	4.322
평소 스트레스 인지 정도		0.000			
평소 스트레스 인지 정도(많이 느낌)	0.214	0.740	1.239	0.349	4.404
평소 스트레스 인지 정도(조금 느낌)	1.470	0.023	4.350	1.229	15.394
평소 스트레스 인지 정도(거의 느끼지 않음)	2.383	0.001	10.838	2.712	43.310
이상지질혈증(있음)	0.187	0.567	1.206	0.635	2.288
빈혈(있음)	0.417	0.365	1.517	0.616	3.738
상수항	-3.952	0.402	0.019		

변수 : 성별, 경제활동 상태, 교육수준, 결혼상태, 신장, 체중, 주관적 건강인지, 1년간 체중 증가량, 평소 스트레스 인지 정도, 이상지질혈증, 빈혈 유병여부 단계 입력

According to the logistic regression results, variables with a statistically significant effect (p < 0.05) on depression experience among overweight individuals included:

- Marital Status (Widowed): B = 1.407, p = 0.048
- Marital Status (Divorced): B = 0.866, p = 0.038
- Self-rated Health (Good): B = -1.861, p = 0.013
- Stress Awareness (Some stress): B = 1.470, p = 0.023
- Stress Awareness (Almost none): B = 2.383, p = 0.001
- → These variables had either a positive or negative effect on the probability of experiencing depression, as reflected by the sign of the coefficient (B value). positive B value: higher likelihood of depression / negative B value: lower likelihood

<표 5> 로지스틱 회귀분석(Logistic Regression) 본 분류표

			예 측	
관측	우울감	분류정확		
		예	아니요	(%)
BMI 과체중 이상	예	2.4	11.1	98.6
우울감 경험	아니요	1.2	85.3	17.5
정확도				87.7

a. 절단값은 .500

→ The results classified using Logistic Regression analysis showed an accuracy of 87.7%.

<표 7> 신경망(Neural Networks) 분석 구조

지 성별 2 경제활동 상태 3 교육 수준 4 결혼상태 5 신장 6 체중 7 주관적 건강인지 8 주관적 체형 인식 9 1년간 체중 변화 여부 10 평소 스트레스 인지 정도 11 이상지질혈증 12 빈혈 도드 수a 788 은닉층 수 1 은닉층 인닉층 1에서 노드의 수a 2 활성화 함수 쌍곡 탄젠트 종속변수 1 BMI 과체중 이상 우울감 경험 모드 수 2 활성화 함수 소프트맥스 오차 함수 교차-엔트로피						
집 교육 수준 4 결혼상태 5 신장 6 채중 7 주관적 건강인지 8 주관적 체형 인식 9 1년간 체중 변화 여부 10 평소 스트레스 인지 정도 11 이상지질혈증 12 변혈 모드 수a 788 은닉층 수 1 은닉층 1에서 노드의 수a 2 활성화 함수 쌍곡 탄젠트 중속변수 1 BMI 과체중 이상 우울감 경험 모드 수 2 활성화 함수 소프트맥스			1	성별		
요인 4 결혼상태 5 신장 6 체중 7 주관적 건강인지 8 주관적 체형 인식 9 1년간 체중 변화 여부 10 평소 스트레스 인지 정도 11 이상지질혈증 12 번혈 보드 수a 788 은닉층 수 1 은닉층 1에서 노드의 수a 2 활성화 함수 쌍곡 탄젠트 종속변수 1 BMI 과체중 이상 우울감 경험 모드 수 2 활성화 함수 소프트맥스			2	경제활동 상태		
유민 유민 유민 등 선장 선장 성당 등 6 체중 기 주관적 건강인지 용 주관적 체형 인식 명소 스트레스 인지 정도 11 이상지질혈증 12 번혈 보드 수 1 은닉층 1에서 노드의 수 1 원제 과체중 이상 우울감 경험 보드 수 2 활성화 함수 오프트맥스			3	교육 수준		
유인 6 채중 7 주관적 건강인지 8 주관적 체형 인식 9 1년간 체중 변화 여부 10 평소 스트레스 인지 정도 11 이상지질혈증 12 번혈 모드 수a 788 은닉층 수 1 은닉층 1에서 노드의 수a 2 활성화 함수 쌍곡 탄젠트 종속변수 1 BMI 과체중 이상 우울감 경험 노드 수 2 활성화 함수 소프트맥스			4	결혼상태		
입력층 유인 7 주관적 건강인지 8 주관적 체형 인식 9 1년간 체중 변화 여부 10 평소 스트레스 인지 정도 11 이상지질혈증 12 빈혈 노드 수a 788 은닉층 수 1 은닉층 1에서 노드의 수a 2 활성화 함수 쌍곡 탄젠트 종속변수 1 BMI 과체중 이상 우울감 경험 노드 수 2 활성화 함수 소프트맥스			5	신장		
입력층		0.01	6	체중		
9 1년간 체중 변화 여부 10 평소 스트레스 인지 정도 11 이상지질혈증 12 빈혈 노드 수a 788 은닉층 수 1 은닉층 1에서 노드의 수a 2 활성화 함수 쌍곡 탄젠트 종속변수 1 BMI 과체중 이상 우울감 경험 노드 수 2 활성화 함수 소프트맥스	입력층	нű	7	주관적 건강인지		
10 평소 스트레스 인지 정도 11 이상지질혈증 12 빈혈 노드 수a 788 은닉층 수 1 은닉층 1에서 노드의 수a 2 활성화 함수 쌍곡 탄젠트 종속변수 1 BMI 과체중 이상 우울감 경험 노드 수 2 활성화 함수 소프트맥스			8	주관적 체형 인식		
11 이상지질혈증 12 빈혈 노드 수a 788 은닉층 수 1 은닉층 1에서 노드의 수a 2 활성화 함수 쌍곡 탄젠트 종속변수 1 BMI 과체중 이상 우울감 경험 노드 수 2 활성화 함수 소프트맥스			9	1년간 체중 변화 여부		
12 번혈 노드 수a 788 은닉층 수 1 은닉층 1에서 노드의 수a 2 활성화 함수 쌍곡 탄젠트 종속변수 1 BMI 과체중 이상 우울감 경험 노드 수 2 활성화 함수 소프트맥스			10	평소 스트레스 인지 정도		
보드 수a 788 은닉층 수 1 은닉층 1에서 노드의 수a 2 활성화 함수 쌍곡 탄젠트 종속변수 1 BMI 과체중 이상 우울감 경험 노드 수 2 활성화 함수 소프트맥스			11	이상지질혈증		
은닉층 수 1 은닉층 1에서 노드의 수a 2 활성화 함수 쌍곡 탄젠트 종속변수 1 BMI 과체중 이상 우울감 경험 노드 수 2 활성화 함수 소프트맥스			12	빈혈		
은닉층은닉층 1에서 노드의 수a2활성화 함수쌍곡 탄젠트종속변수1BMI 과체중 이상 우울감 경험노드 수2활성화 함수소프트맥스		노드	수a	788		
활성화 함수 쌍곡 탄젠트 종속변수 1 BMI 과체중 이상 우울감 경험 노드 수 2 활성화 함수 소프트맥스		은닉층	수	1		
종속변수 1 BMI 과체중 이상 우울감 경험 노드 수 2 활성화 함수 소프트맥스	은닉층	은닉층 1에서	노드의 수a	2		
호력층 보드 수 2 활성화 함수 소프트맥스		활성화	함수	쌍곡 탄젠트		
출력층 활성화 함수 소프트맥스		종속변수	1	BMI 과체중 이상 우울감 경험		
활성화 함수 소프트맥스 	축려 츳	노드	수	2		
오차 함수 교차-엔트로피	270	활성화	함수	소프트맥스		
		오차	함수	교차-엔트로피		

a. 편향 단위 제외

- 12 input variables
- One hidden layer with two nodes
- Uses the hyperbolic tangent activation function in the hidden layer and the softmax function in the output layer
- optimized using cross-entropy error

<표 8> 신경망(Neural Networks) 분류분석 결과

구 분	예측					
	예	아니요	정확도 퍼센트(%)			
예	2.6	7.7	98.3			
아니요	1.5	88.2	25.0			
정혹	ł도(%)		90.8			

종속변수 : BMI 과체중 이상 우울감 경험


→ The results classified using Neural Networks analysis showed an accuracy of 90.8%.

Case 1 (Hwang, 2024)

Results

<표 9> BMI 과체중 이상 우울감 경험 예측 모형 요약

모형 요약						
	성장방법	CHAID				
	종속변수	우울감 경험				
지정 사항	독립변수	성별, 경제활동 상태, 교육 수준, 결혼상태, 신장, 체중, 주관적 건강인지, 주관적 체형 인식, 1년간체중 변화 여부, 1년간 체중 감소량, 1년간 체중증가량, 이상지질혈증, 빈혈				
	검증	분할 표본				
	최대 나무 깊이	3				
	부모 노드의 최소 케이스	100				
	자식 노드의 최소 케이스	50				
	독립변수 포함	주관적 건강인지, 신장, 1년간 체중 변화 여부, 경제활동 상태				
결과	노드 수	10				
	터미널 노드 수	6				
	깊이	2				



<그림 4> BMI 과체중 이상 우울감 경험 의사결정트리(Decision Tree)

- maximum tree depth: 3, parent node size: 100, minimum child node size: 50
- depth: 2
- total nodes: 10, terminal nodes: 6
- key variables: self-rated health, employment status, weight change over 1 year, height

<표 10> BMI 과체중 이상 우울감 경험 예측 모형 분류 요약

구 분		예측	
丁 正	예	아니요	정확도(%)
예	90.5	0	100.0
아니요	9.2	0	0.0
정혹	탁도(%)		90.5

성장 방법 : CHAID

종속변수 : BMI 과체중 이상 우울감 경험

→ The results classified using CHAID Decision Tree analysis showed an accuracy of 90.5%.

<표 11> 분석방법 및 정확도 비교

구 분	모형 분석결과		
	신경망 (Neural Network)	의사결정나무 (Decision Tree)	로지스틱 회귀분석 (Logistic Regression)
정확도	90.8%	90.5%	87.7% TH &

- Neural Network achieved the highest accuracy; Decision Tree was best in interpretability, although Logistic Regression showed decent accuracy.
- Social isolation and self-rated health consistently emerged as key predictors.
- Psychosocial effects of obesity may outweigh the role of BMI itself.
- This study supports the use of basic public health survey data in mental health prediction.

Limitations



Cross-sectional data limits causal inference.



Self-reported survey responses may have bias.



Psychosocial variables like isolation/stress are hard to quantify precisely.

Case 2

Predicting Overweight and Obesity Status Among Malaysian Working Adults
With Machine Learning or Logistic Regression:
Retrospective Comparison Study

by Jyh Eiin Wong

Case 2 (Wong et al., 2022)

Dataset

Malaysia's Healthiest Workplace Survey 2019.

Preprocessing

735 subjects excluded (non-Malaysian, pregnant, or implausible BMI values)

473 variables excluded (irrelevant or >20% missing)

Categorical variables into binary format using one-hot encoding.

Population

16,860 working adults in Malaysia

Data Partitioning


70% (11,803 individuals) used for training 30% (5,057 individuals) used for validation

Overweight / Obesity Proportion

4,934 individuals (41.8%) in the training set were overweight or obese

Model Input

Total of 165 normalized features Includes 120 binary variables






Machine Learning

- XGBoost
- Random Forest(RF)
- SVM



Data Mining


Logistic Regression



XGBoost (Extreme Gradient Boosting)

XGBoost builds decision trees sequentially to reduce prediction errors (residuals) step by step.

It combines gradient-based optimization, regularization, and parallel processing to create a highly accurate and robust model that is resistant to overfitting.




Random Forest

An ensemble learning method that builds multiple decision trees and aggregates their results to make more accurate and robust predictions.

Each tree is trained on a random sample of the data (bootstrapping).

At each split, a random subset of features is considered.

Final prediction = majority vote (classification) or average (regression)



SVM (Support Vector Machine)

A supervised learning algorithm that finds the optimal boundary (hyperplane) to separate different classes with the maximum margin.

Identifies support vectors, the most critical data points near the margin

Maximizes the distance (margin) between classes

Can handle non-linear boundaries using kernel functions

Table 1. Performance of machine-learning algorithms and logistic regression in obesity prediction.


Metrics	Gradient boosting, mean (95% CI)	Random forest, mean (95% CI)	Support vector machine, mean (95% CI)	Logistic regression, mean (95% CI)
Accuracy ^a	0.73 (0.72-0.75)	0.73 (0.71-0.74)	0.72 (0.71-0.73)	0.71 (0.70-0.72)
Sensitivity ^a	0.67 (0.65-0.69)	0.60 (0.58-0.62)	0.65 (0.62-0.67)	0.56 (0.54-0.58)
Specificitya	0.78 (0.76-0.79)	0.82 (0.80-0.83)	0.77 (0.76-0.79)	0.82 (0.81-0.83)
Area under the curve ^b	0.81 (0.79-0.82)	0.80 (0.79-0.81)	0.80 (0.78-0.81)	0.78 (0.77-0.80)

XGBoost showed the best overall performance, especially in identifying obese individuals (high sensitivity and AUC).

While Logistic Regression is simpler, it tends to miss more obese individuals.

However, all models had AUCs above 0.78, indicating they are all practically usable for real-world screening.

Figure 2. Receiver operating characteristic curves with corresponding AUC values; AUC values for each model are also presented in Table 2. AUC: area under the curve.




ROC(Receiver Operating Characteristic) Curve

A graphical representation used to evaluate the performance of classification models

- The diagonal line represents a model that makes random guesses (AUC = 0.5). The further the curve is from the diagonal and toward the top-left corner, the better the model.
- XGBoost the highest, Logistic regression the lowest. Still they are all good models.

Figure 3. Variable importance plots of obesity predictors for extreme gradient boosting (A), random forest (B), support vector machine (C) and logistic regression (D) models. The top 10 predictors are shown for all models.



A person's subjective perception of their weight (weight satisfaction) was the most powerful predictor of obesity status.

Those who are dissatisfied with their body weight were more likely to be overweight or obese.

- In conclusion, among the predictors, weight satisfaction was the most influential factor. This suggests that obesity interventions should not only focus on physical metrics, but also include psychological and perceptual components such as body image, self-esteem, and health awareness to promote sustainable behavior change.
- In the modeling perspective, among the three machine learning models (XGBoost, Random Forest, and SVM), XGBoost showed the highest accuracy and AUC.
- However, the logistic regression model was comparable to the overall performance of the ML models or even better in some parts.
- This suggests that even simple, interpretable models like logistic regression can perform competitively, and may be preferable when interpretability and practical implementation are important.

Limitations



Self-reported weight and height may have led to misclassification and underestimation of obesity prevalence.



No external validation: Models were tested on the same dataset, which may limit generalizability.



High proportion of binary variables (73%) may have reduced the advantage of nonlinear ML algorithms.

References

Citations

[Case 1:

Hwang, K.–I. (2024). Exploring factors for predicting depression experiences beyond BMI overweight using data mining models in the post–COVID–19 era (Doctoral dissertation). Korea University, Department of Health Policy and Management. https://doi.org/10.23186/korea.000000277951.11009.0000395

[Case 2:

Wong, J., Yamaguchi, M., Nishi, N., Araki, M., & Wee, L. (2022). Predicting overweight and obesity status among Malaysian working adults with machine learning or logistic regression: Retrospective comparison study. JMIR Formative Research, 6(12), e40404. https://doi.org/10.2196/40404

Mank you!

Data Mining, ITM, SeoulTech, 2025 Spring

20102105 Kim Seungjun 21102052 Lee Jeong-Yun 21102061 Hwang Hyunmin